Podstawy R i RStudio

Tomasz Olczyk

Dlaczego programatycznie w Rmarkdown

Reprodukowalność i literate programming

Wszystkie wyniki (tabele, wykresy itp) powinny byc procedualnie i reprodukowalnie generowane z zapisanego kodu, zapisane w prostym formacie opartym na tekście. Możliwość reprodukowania własnej pacy jest kluczowa w nauce, ale także ze względów czysto pragmatycznych. Osobą, która będzie najczęściej reprodukować Twoje wyniki jesteś Ty za sześć miesięcy.

Celem jest maksymalnie programatyczne tworzenie grafiki. Staramy się nie używać sposobów które nie są programatycznie reprodukowalne.

Zadania:

- 1. pisanie kodu
- 2. analiza wyników 3 notatki

Dlatego używamy RMakdown. Jest to czysto tekstowy dokument, któy umożliwia robienie tych wszystkich rzeczy, w sposób reprodukowalny i zapisany w możliwie odporny sposób.

Projekt elementy podstawowe

File > New project

File > New File > Rmarkdown

znak # oznacza komentarz wewnętrz segmentu kodu w Rmakdown odnosi się do poziomu nagłówka

skróty klawiszowe Ctrl+Alt+ I - nowy segment kodu w Windowsie Cmd+Alt + I = nowy segment kodu w Mac os

RStudio podstawwowe informacje

- Panele
- Pliki
- Skrypty
- RMarkdown
- Konsola

Instalacja pakietów

Pakiet R jest kolekcją funkcji, danych i dokumentacji, która rozszerza możliwości bazowego R

Poniższy segment jest nazywany code chunk. Pliki R markdown składają się z nagłówka, segmentów tekstu i specjalnie oznaczonych segmentów kodu. Skrypty składają się z kodu i komentarzy poprzedzonych #. W markdown "domyślną" treścią jest tekst "do czytania", kod jest dodatkiem, dlatego znajduje się w specjalnie zaznaczonych segmentach. Raportom w R markdown poświęcimy oddzielne zajęcia.

W skryptach jest na odwrót, dlatego tekst trzeba poprzedzać # żeby program nie uznał go za kod.

Biblioteki instalujmy funkcją install.packages() której argumentem jest nazwa biblioteki w cudzysłowie. Bibliotekę wystarczy zainstalować raz.

```
# kod w tym segmencie instaluje bibliotekę tidyverse
#install.packages("tidyverse")
# hash przed kodem sprawia, że znaki po nim są traktowane jak komentarz, kod nie będzie wykonany
```

Wczytywanie pakietów (bibliotek)

Pakiety wczytujemy funkcją library(). Biblioteki dobrze jest wczytywać na początku analizy. Biblioteka powinna być wczytana przed użyciem funkcji w niej zawartej. Można użyć funkcji bez wczytywania używając składni biblioteka::funkcja

```
library(tidyverse)
```

```
## -- Attaching core tidyverse packages ----- tidyverse 2.0.0 --
## v dplyr
              1.1.3
                        v readr
                                    2.1.4
## v forcats
              1.0.0
                                    1.5.0
                        v stringr
## v ggplot2 3.5.1
                        v tibble
                                    3.2.1
## v lubridate 1.9.3
                        v tidyr
                                    1.3.0
## v purrr
              1.0.2
## -- Conflicts ----- tidyverse conflicts() --
## x dplyr::filter() masks stats::filter()
## x dplyr::lag()
                    masks stats::lag()
## i Use the conflicted package (<a href="http://conflicted.r-lib.org/">http://conflicted.r-lib.org/</a>) to force all conflicts to become error
#install.packages("gapminder")
```

Obiekty i funkcje

library(gapminder)

W R wszystko jest obiektem.

Nazwy obiektów muszą rozpoczynać się od litery i mogą zawierać tylko litery, cyfry znak oraz . .

Wszystko ma nazwę:

zmienne, dane, funkcje. Do nadawania nazw nie wolno używać m.in FALSE, TRUE, Inf, for, else, break, function. Lepiej nie używać we własnych nazwach nazw funkcji, szczególnie z pakiety podstawowego jak c() - konkatentacja, q(), mean(), var(), range() i podobnych

Wszystko jest obiektem:

```
# przypisuje kolekcję liczb do nazwy moje liczby
# operator przypisania <- można uzyskać skrótem Alt - na Windowsie, Opt - na mac
moje_liczby <- c(1, 2, 3, 5, 25) # funkcja c() tworzy wektor czyli uporządkowaną kolekcję elementów je</pre>
```

Operator przypisania skróty: -mac os: Opt + - -Win: Alt + -

Po przypisaniu i wykonaniu kodu obiekt pojawi się w przestrzeni roboczej: okno environment

Operator przypisania łączy obiekt z nazwą

Działania wykonuje się za pomocą funkcji:

Kiedy chcemy żeby funkcja wykonała jakieś działanie wywołujemy ją. Funkcje mają nawiasy na końcu swojej nazwy. Funkcje wykonują działania na podstawie wartości przyjmowanych przez ich argumenty

```
nazwa\_funkcji(argument1 = , argument2 = , argument2 = )
```

Argumenty zawsze oddzielone są przecinkami

```
# funkcja licząca średnią
mean()
```

```
## Error in mean.default(): argument "x" is missing, with no default
```

Komunikat o błędzie: Error in mean.default(): argument "x" is missing, with no default W tym wypadku infomuje o tym, że wartość argumentu x nie została podana Ogólnie jeśli wartość argumentu nie jest liczbą, obiektem istniejącym w przestrzeni roboczej albo wartością logiczną to jest podawana w cudzysłowie (por instalowanie biblioteki versus wczytywanie biblioteki)

najczęście nie trzeba podawać nazw argumentów, wystarczy podanie ich wartości w odpowiedniej kolejnoś mean(moje_liczby)

```
## [1] 7.2
```

Rezultaty działania funkcji można przypisać do obiektów

```
podsumowanie <- summary(moje_liczby)
podsumowanie # wyświetla obiekt w konsoli</pre>
```

```
## Min. 1st Qu. Median Mean 3rd Qu. Max.
## 1.0 2.0 3.0 7.2 5.0 25.0
```

Funkcje zawarte są w pakietach (bibliotekach)

Żeby użyć funkcji musimy mieć zainstalowaną i wczytaną bibliotekę (package) z której pochodzi funkcja. Wczytywanie funkcją library można pominąć wskazując bibliotekę i funkcję w ten sposób nazwa_biblioteki::nazwa_funkcji

W R działamy na obiektach. Obiektami manipulujemy pzekazując informacje o nich do funkcji. Funkcje wykonują operacje na obiektach i zwracają wyniki.

np.

```
# zwraca tabelę liczności elementów
table(moje_liczby)
## moje_liczby
## 1 2 3 5 25
   1 1 1 1 1
# zwraca odchylenie standardowe
sd(moje_liczby)
## [1] 10.05982
# mnoży każdy element przez 5
moje_liczby * 5
## [1] 5 10 15 25 125
# dodaje 5 do każdego elementu
moje_liczby + 5
## [1] 6 7 8 10 30
# operacja wektoryzowana, kolejne elementy jednego wektora dodane do kolejnych elementów drugiego wykto
moje_liczby + moje_liczby
## [1] 2 4 6 10 50
Każdy obiekt ma klasę, którą możemy spawdzic funkcją class()
class(moje_liczby)
## [1] "numeric"
podsumowanie <- summary(moje_liczby)</pre>
class(podsumowanie)
## [1] "summaryDefault" "table"
class(summary)
## [1] "function"
```

Operacje wykonywane na obiektach mogą skutkować zmianą ich klasy:

```
nowy_wektor <- c(moje_liczby, "jabłko")
class(nowy_wektor)</pre>
```

[1] "character"

Zbiory danych zaimportowane do też są obiektami. W R jest kilka typów obiektów służących do przechowywania danych ale najbadziej typowym jest ramka danych: data frame. Ramka danych to prostokątna tabela zlożona z wierszy (obserwacji) i kolumn (zmiennych). Kolumny w ramce danych mogą być różnej klasy.

Liczby

```
class(1)
```

[1] "numeric"

Znaki

```
class("1")
```

[1] "character"

Logiczne

```
two <- 2 # strzałka jest operatorem przypisania, przypisuje obiekt do nazwy

Two <- 2 #wielkie litery mają znaczenie
```

Operatory

```
logiczne <- two == Two # podwójny znak = oznacza w R równa się
logiczne
```

```
## [1] TRUE
```

```
nierówna_się <- two != Two
nierówna_się
```

[1] FALSE

Obiekt i operator przypisania. Zapisuje obiekt "data", zawierający dane gapminder

```
data <- (gapminder)</pre>
```

Wgląd w dane w ramce

```
## tibble [1,704 x 6] (S3: tbl_df/tbl/data.frame)
## $ country : Factor w/ 142 levels "Afghanistan",..: 1 1 1 1 1 1 1 1 1 1 1 1 ...
## $ continent: Factor w/ 5 levels "Africa","Americas",..: 3 3 3 3 3 3 3 3 3 3 3 3 3 ...
## $ year : int [1:1704] 1952 1957 1962 1967 1972 1977 1982 1987 1992 1997 ...
## $ lifeExp : num [1:1704] 28.8 30.3 32 34 36.1 ...
## $ pop : int [1:1704] 8425333 9240934 10267083 11537966 13079460 14880372 12881816 13867957 163
## $ gdpPercap: num [1:1704] 779 821 853 836 740 ...
```

Wyświetla 6 pierwszych wierszy

head(data)

```
## # A tibble: 6 x 6
##
    country
                continent year lifeExp
                                             pop gdpPercap
    <fct>
                <fct>
                          <int>
                                  <dbl>
                                           <int>
                                                     <dbl>
## 1 Afghanistan Asia
                          1952
                                   28.8 8425333
                                                      779.
## 2 Afghanistan Asia
                         1957
                                   30.3 9240934
                                                      821.
## 3 Afghanistan Asia
                           1962
                                   32.0 10267083
                                                      853.
## 4 Afghanistan Asia
                           1967
                                   34.0 11537966
                                                      836.
## 5 Afghanistan Asia
                           1972
                                   36.1 13079460
                                                      740.
## 6 Afghanistan Asia
                           1977
                                   38.4 14880372
                                                      786.
```

Wyświetla ramkę danych w lewym panelu

View(data)

Wyświetla ostatnich sześć wierszy

tail(data)


```
## # A tibble: 6 x 6
##
     country continent year lifeExp
                                           pop gdpPercap
     <fct>
              <fct>
                        <int>
                                <dbl>
                                                   <dbl>
                                         <int>
## 1 Zimbabwe Africa
                                 60.4 7636524
                                                    789.
                         1982
## 2 Zimbabwe Africa
                         1987
                                 62.4 9216418
                                                    706.
                         1992
                                 60.4 10704340
## 3 Zimbabwe Africa
                                                    693.
## 4 Zimbabwe Africa
                         1997
                                 46.8 11404948
                                                    792.
## 5 Zimbabwe Africa
                         2002
                                 40.0 11926563
                                                    672.
## 6 Zimbabwe Africa
                         2007
                                 43.5 12311143
                                                    470.
```

Funkcja glimpse z pakietu dplyr. Nazwa funkcji poprzedzona dwukropkiem i nazwą biblioteki informuje/ustala, z której biblioteki ma być zastosowana funkcja o danej nazwie. Przydatne, gdy jest wiele funkcji o tych samych nazwach z różnych bibliotek,

```
dplyr::glimpse(data)
## Rows: 1,704
## Columns: 6
## $ country <fct> "Afghanistan", "Afghanistan", "Afghanistan", "Afghanistan", ~
## $ continent <fct> Asia, ~
## $ year <int> 1952, 1957, 1962, 1967, 1972, 1977, 1982, 1987, 1992, 1997, ~
## $ lifeExp <dbl> 28.801, 30.332, 31.997, 34.020, 36.088, 38.438, 39.854, 40.8~
## $ pop <int> 8425333, 9240934, 10267083, 11537966, 13079460, 14880372, 12~
## $ gdpPercap <dbl> 779.4453, 820.8530, 853.1007, 836.1971, 739.9811, 786.1134, ~
Wektory
Tworzenie wektorów
partie <- c("KO", "PiS", "Lewica", "Konfederacja", "TD")</pre>
partie
## [1] "KO"
                     "PiS"
                                                    "Konfederacja" "TD"
                                     "Lewica"
Wektor napisów
class(partie)
## [1] "character"
Wektor liczb
sondaż <- c(29, 35, 10, 10, 10)
typeof(sondaż)
## [1] "double"
# w języku R klasa double reprezentuje liczby zmiennoprzecinkowe o podwójnej precyzji (double precision
class(sondaż)
## [1] "numeric"
Indeksowanie
wektor <- 3:103
```

```
wektor[0]
## integer(0)
wektor[1]
## [1] 3
LETTERS
## [1] "A" "B" "C" "D" "E" "F" "G" "H" "I" "J" "K" "L" "M" "N" "O" "P" "Q" "R" "S"
## [20] "T" "U" "V" "W" "X" "Y" "Z"
co_drugi <- seq(from = 1, to = length(LETTERS), by = 2)</pre>
LETTERS[co_drugi]
## [1] "A" "C" "E" "G" "I" "K" "M" "O" "Q" "S" "U" "W" "Y"
Ramki danych
Matryca z dwóch wektorów
matryca <- cbind(partie, sondaż)</pre>
matryca
                       {\tt sonda}\dot{\tt z}
##
        partie
## [1,] "KO"
                       "29"
                       "35"
## [2,] "PiS"
## [3,] "Lewica"
                       "10"
## [4,] "Konfederacja" "10"
## [5,] "TD"
glimpse(matryca)
## chr [1:5, 1:2] "KO" "PiS" "Lewica" "Konfederacja" "TD" "29" "35" "10" "10" ...
## - attr(*, "dimnames")=List of 2
   ..$ : NULL
##
   ..$ : chr [1:2] "partie" "sondaż"
ramka_danych <- data.frame(partie, sondaż)</pre>
glimpse(ramka_danych)
## Rows: 5
## Columns: 2
## $ partie <chr> "KO", "PiS", "Lewica", "Konfederacja", "TD"
## $ sondaż <dbl> 29, 35, 10, 10, 10
```

Jak połączyć wektory nierównych długości w ramkę danych: link



Wczytywanie danych

?read.delim

Funkcje mają zazwyczaj długą listę argumentów, z których większość ma domyślne wartości.

```
read.table(file,
           header = FALSE,
           sep = "",
           quote = "\"'",
           dec = ".", numerals = c("allow.loss", "warn.loss", "no.loss"),
           row.names, col.names,
           as.is = !stringsAsFactors,
           na.strings = "NA",
           colClasses = NA,
           nrows = -1,
           skip = 0,
           check.names = TRUE,
           fill = !blank.lines.skip,
           strip.white = FALSE,
           blank.lines.skip = TRUE,
           comment.char = "#",
           allowEscapes = FALSE, flush = FALSE,
           stringsAsFactors = FALSE,
           fileEncoding = "",
           encoding = "unknown",
           text,
           skipNul = FALSE)
```

?read.csv()

?readr::read_delim

```
read_delim(
  file,
  delim = NULL,
  quote = "\"",
  escape_backslash = FALSE,
  escape_double = TRUE,
```

```
col_names = TRUE,
  col_types = NULL,
  col select = NULL,
  id = NULL,
  locale = default_locale(),
  na = c("", "NA"),
  quoted_na = TRUE,
  comment = "",
  trim_ws = FALSE,
  skip = 0,
  n_{max} = Inf,
  guess_max = min(1000, n_max),
  name_repair = "unique",
  num_threads = readr_threads(),
  progress = show_progress(),
 show_col_types = should_show_types(),
 skip_empty_rows = TRUE,
  lazy = should_read_lazy()
read_csv(
  file,
 col_names = TRUE,
 col_types = NULL,
 col_select = NULL,
  id = NULL,
  locale = default_locale(),
  na = c("", "NA"),
  quoted_na = TRUE,
  quote = "\"",
  comment = "",
  trim_ws = TRUE,
  skip = 0,
  n_{max} = Inf,
  guess_max = min(1000, n_max),
  name_repair = "unique",
  num_threads = readr_threads(),
 progress = show_progress(),
 show_col_types = should_show_types(),
 skip_empty_rows = TRUE,
 lazy = should_read_lazy()
)
read_csv2(
  file,
  col_names = TRUE,
  col_types = NULL,
  col_select = NULL,
  id = NULL,
  locale = default_locale(),
 na = c("", "NA"),
  quoted_na = TRUE,
  quote = "\"",
```

```
comment = "",
  trim_ws = TRUE,
  skip = 0,
  n \max = Inf,
  guess_max = min(1000, n_max),
  progress = show_progress(),
 name_repair = "unique",
 num_threads = readr_threads(),
 show_col_types = should_show_types(),
 skip_empty_rows = TRUE,
 lazy = should_read_lazy()
read_tsv(
 file,
  col_names = TRUE,
 col_types = NULL,
  col_select = NULL,
 id = NULL,
 locale = default_locale(),
  na = c("", "NA"),
  quoted_na = TRUE,
  quote = "\"",
  comment = "",
  trim_ws = TRUE,
  skip = 0,
  n_{max} = Inf,
  guess_max = min(1000, n_max),
  progress = show_progress(),
 name_repair = "unique",
 num_threads = readr_threads(),
 show_col_types = should_show_types(),
 skip_empty_rows = TRUE,
  lazy = should_read_lazy()
)
```

panteon <- read_csv("https://raw.githubusercontent.com/Tomasz-Olczyk/wizualizacjaR/main/podstawy/panteon</pre>

```
## Rows: 11341 Columns: 13
## -- Column specification ------
## Delimiter: ","
## chr (7): name, countryName, countryCode3, continentName, gender, industry, d...
## dbl (6): LAT, LON, birthyear, L_star, HPI, AverageViews
##
## i Use 'spec()' to retrieve the full column specification for this data.
## i Specify the column types or set 'show_col_types = FALSE' to quiet this message.
```

Zapisywanie danych

analogicznie funkcjami write*

?write.table


Pozwalajmy sobie na błędy

R zawsze robi to co mu każemy zrobić, ale nie zawsze to, co chcemy żeby zrobił. Inaczej mówiąc R traktuje wszystkie polecenia literalnie.

Będziemy popełniać błędy i będzie ich mnóstwo. Błędy pomagają nauczyć się programowania w R.

Typowe błędy: niedomknięty nawias, niekompletne wyrażanie (+ w konsoli, kursor + Esc) częstybłąd ggplot to + w niewłaściwm miejscy


```
ggplot(data = mpg, aes(x = displ, y = hwy))
```



```
+ geom_point()
```

```
## Error:
## ! Cannot use '+' with a single argument.
## i Did you accidentally put '+' on a new line?
```

```
ggplot(data = mpg, aes(x = displ, y = hwy)) +
geom_point()
```



Inne typy plików wejściowych

Praktycznie każde działanie w R można wykonać co najmniej na kilka sposobów za pomocą różnych funkcji różnych pakietów. Dotyczy to zarówno grafiki jak i wczytywania plików.

Do wczytywania plików excela można wykorzystać bibliotekę readxl

```
#install.packages("readxl")
library(readxl)
```

Biblioteka ta ma kilka funkcji wczytujących pliki excelowskie np read_excel która sama ustala czy plik ma rozszerzenie xls czy xlsx ale także funkcje read_xls, i read_xlsx, których możemy użyć jeśli znamy rozszerzenie pliku

```
read_excel(
  path,
  sheet = NULL,
  range = NULL,
  col_names = TRUE,
  col_types = NULL,
  na = "",
```

```
trim_ws = TRUE,
  skip = 0,
 n_{max} = Inf,
  guess_{max} = min(1000, n_{max}),
 progress = readxl_progress(),
  .name_repair = "unique"
podatki <- read_excel(</pre>
  "../podstawy/Chapter14TablesFigures.xlsx", #uwaga musimy być we właściwym katalogu roboczym, żeby ta
  sheet = "TS14.1", #wybieramy arkusz z pliku
  skip = 3 # usuwamy trzy pierwsze wiersze
## New names:
## * '' -> '...1'
## * '' -> '...6'
## * '' -> '...9'
## * '' -> '...11'
## * ' ' -> ' . . . 14'
str(podatki)
## tibble [120 x 15] (S3: tbl_df/tbl/data.frame)
## $ ...1
                                                        : chr [1:120] "1900" "1901" "1902" "1903" ...
## $ U.S.
                                                        : num [1:120] 0 0 0 0 0 0 0 0 0 0 ...
## $ U.K.
                                                        : num [1:120] 0 0 0 0 0 ...
## $ Germany
                                                        : num [1:120] 0.03 0.03 0.03 0.03 0.03 0.03 0.03
                                                        : num [1:120] 0 0 0 0 0 0 0 0 0 0 ...
## $ France
## $ ...6
                                                        : logi [1:120] NA NA NA NA NA NA ...
## $ U.S.
                   (top marginal rate on earned income): num [1:120] 0 0 0 0 0 0 0 0 0 ...
## $ U.S.
                   (top effective rate)
                                                        : num [1:120] 0 0 0 0 0 0 0 0 0 ...
## $ ...9
                                                        : logi [1:120] NA NA NA NA NA NA ...
## $ U.K.
                   (top marginal rate on earned income): num [1:120] 0 0 0 0 ...
## $ ...11
                                                        : logi [1:120] NA NA NA NA NA NA ...
## $ France (income tax)
                                                        : num [1:120] 0 0 0 0 0 0 0 0 0 0 ...
## $ France (CSG)
                                                        : num [1:120] 0 0 0 0 0 0 0 0 0 0 ...
## $ ...14
                                                        : logi [1:120] NA NA NA NA NA NA ...
## $ Japan (Saez-Morigushi Table A0)
                                                        : num [1:120] 0.055 0.055 0.055 0.0935 0.2035 ...
dplyr::glimpse(podatki)
## Rows: 120
## Columns: 15
## $ ...1
                                                          <chr> "1900", "1901", "1~
## $ U.S.
                                                          <dbl> 0.000, 0.000, 0.00~
## $ U.K.
                                                          <dbl> 0.00000000, 0.0000~
## $ Germany
                                                          <dbl> 0.03, 0.03, 0.03, ~
## $ France
                                                          <dbl> 0.00, 0.00, 0.00, ~
                                                          <lg>1> NA, NA, NA, NA, NA~
## $ ...6
## $ 'U.S.
                   (top marginal rate on earned income) ' <dbl> 0.000, 0.000, 0.00~
```

```
<dbl> 0.000, 0.000, 0.00~
## $ 'U.S.
                    (top effective rate) '
## $ ...9
                                                           <lgl> NA, NA, NA, NA, NA~
## $ 'U.K.
                    (top marginal rate on earned income) ' <dbl> 0.00000000, 0.0000~
                                                           <lgl> NA, NA, NA, NA, NA~
## $ ...11
## $ 'France (income tax)'
                                                           <dbl> 0.00, 0.00, 0.00, ~
## $ 'France (CSG)'
                                                           <dbl> 0, 0, 0, 0, 0, 0, ~
## $ ...14
                                                           <lgl> NA, NA, NA, NA, NA~
                                                           <dbl> 0.0550, 0.0550, 0.~
## $ 'Japan (Saez-Morigushi Table AO)'
podatki$...1 <- as.numeric(podatki$...1)</pre>
```

Warning: NAs introduced by coercion

```
dplyr::glimpse(podatki)
```

```
## Rows: 120
## Columns: 15
## $ ...1
                                                           <dbl> 1900, 1901, 1902, ~
## $ U.S.
                                                           <dbl> 0.000, 0.000, 0.00~
## $ U.K.
                                                           <dbl> 0.00000000, 0.0000~
## $ Germany
                                                           <dbl> 0.03, 0.03, 0.03, ~
## $ France
                                                           <dbl> 0.00, 0.00, 0.00, ~
## $ ...6
                                                           <lg>1> NA, NA, NA, NA, NA~
## $ 'U.S.
                   (top marginal rate on earned income) ' <dbl> 0.000, 0.000, 0.00~
## $ 'U.S.
                   (top effective rate) '
                                                           <dbl> 0.000, 0.000, 0.00~
                                                           <lg>1> NA, NA, NA, NA, NA~
## $ ...9
## $ 'U.K.
                   (top marginal rate on earned income) ' <dbl> 0.00000000, 0.0000~
## $ ...11
                                                           <lg>1> NA, NA, NA, NA, NA~
## $ 'France (income tax)'
                                                           <dbl> 0.00, 0.00, 0.00, ~
## $ 'France (CSG)'
                                                           <dbl> 0, 0, 0, 0, 0, 0, ~
## $ ...14
                                                           <lgl> NA, NA, NA, NA, NA~
## $ 'Japan (Saez-Morigushi Table A0)'
                                                           <dbl> 0.0550, 0.0550, 0.~
```

Dobrą ale nieco wolniejszą biblioteką jest openxlsx

```
#install.packages(openxlsx)
library(openxlsx)
```

```
read.xlsx(
xlsxFile,
sheet,
startRow = 1,
colNames = TRUE,
rowNames = FALSE,
detectDates = FALSE,
skipEmptyRows = TRUE, # pominie puste wiersze
skipEmptyCols = TRUE, # pominie puste kolumny
rows = NULL,
cols = NULL,
check.names = FALSE,
sep.names = ".",
namedRegion = NULL,
```


```
na.strings = "NA",
fillMergedCells = FALSE
)
```

```
plot(y =podatki_open$U.S.,
    x = podatki_open$X1,
    type = "l",
    col = "steelblue",
    ylim = c(0,1))
```

Warning in xy.coords(x, y, xlabel, ylabel, log): NAs introduced by coercion

```
lines(y =podatki_open$U.K.,
    x = podatki_open$X1,
    col = "orange")
```

Warning in xy.coords(x, y): NAs introduced by coercion




Raczej potrzebujemy schodków bo podatek pozostaje na takim samym poziomie przez jakiś czas

```
plot(y =podatki_open$U.S.,
    x = podatki_open$X1,
    type = "s",
    col = "steelblue",
    ylim = c(0,1))
```

Warning in xy.coords(x, y, xlabel, ylabel, log): NAs introduced by coercion

```
lines(y =podatki_open$U.K.,
    x = podatki_open$X1,
    col = "orange",
    type = "s")
```

Warning in xy.coords(x, y): NAs introduced by coercion



Indeksowanie C.D.

```
pięć_kolumn <- panteon[,1:5]

sześć_wierszy <- panteon[1:6,]

sześć_wierszy_pięciu_kolumn <- panteon[1:6, 1:5]

sześć_wierszy_pięciu_kolumn</pre>
```

```
## # A tibble: 6 x 5
    name countryName countryCode3 LAT
##
                                                       LON
    <chr>
                    <chr>
                                  <chr>
                                              <dbl>
##
                                                      <dbl>
## 1 Abraham Lincoln UNITED STATES USA
                                              37.6 -85.7
## 2 Aristotle Greece GRC
                                               40.3
                                                      23.5
## 3 Ayn Rand Russia
                                  RUS
                                               60.0
                                                     30.3
## 4 Andre Agassi UNITED STATES USA
                                               36.1 -115.
## 5 Aldous Huxley UNITED KINGDOM GBR
                                              51.2
                                                     -0.61
## 6 Andrei Tarkovsky Russia
                                 RUS
Indeksowanie wektora
panteon$countryName[1:6]
## [1] "UNITED STATES" "Greece"
                                      "Russia"
                                                      "UNITED STATES"
## [5] "UNITED KINGDOM" "Russia"
piqta_kolumna <- panteon[,5]</pre>
Czwarty element z piątej kolumny
piąta_kolumna[4,]
## # A tibble: 1 x 1
##
      LON
    <dbl>
##
## 1 -115.
Zakres
range(panteon$HPI)
## [1] 9.879447 31.993795
Średnia
mean(panteon$HPI)
## [1] 22.30824
summary
summary(panteon$domain)
##
     Length
               Class
                          Mode
```

##

11341 character character

class(panteon\$domain)

[1] "character"

table(panteon\$gender)


Female Male ## 1495 9846

Przykłady wykresów w bazowym R

 ${\rm histogram}$


hist(panteon\$HPI)

Histogram of panteon\$HPI




wykres pudełkowy

boxplot(panteon\$HPI ~ panteon\$gender)



wykres pudełkowy według kategorii

boxplot(HPI~gender, data = panteon)



Zadanie: boxplot HPI według kontynentów

Wykres słupkowy.


1. zliczenie funkcją table

(domeny <- table(panteon\$domain))</pre>

```
##
##
                    ARTS
                                BUSINESS & LAW
                                                         EXPLORATION
##
                    2866
                                            108
                                                                  102
##
             HUMANITIES
                                  INSTITUTIONS
                                                       PUBLIC FIGURE
                                                                  358
##
                    1329
                                           3456
## SCIENCE & TECHNOLOGY
                                        SPORTS
##
                    1366
                                           1756
```

2. wykres słupkowy

```
barplot(domeny,
    horiz = TRUE,
    las =1)
```




?barplot

elemnty dodatkowe

```
## Warning in (function (s, units = "user", cex = NULL, font = NULL, vfont =
## NULL, : conversion failure on 'mediczyzna' in 'mbcsToSbcs': dot substituted for
## <c4>
## Warning in (function (s, units = "user", cex = NULL, font = NULL, vfont =
## NULL, : conversion failure on 'mediczyzna' in 'mbcsToSbcs': dot substituted for
## <99>
## Warning in (function (s, units = "user", cex = NULL, font = NULL, vfont =
```


```
## NULL, : conversion failure on 'meżczyzna' in 'mbcsToSbcs': dot substituted for
## <c5>
## Warning in (function (s, units = "user", cex = NULL, font = NULL, vfont =
## NULL, : conversion failure on 'meżczyzna' in 'mbcsToSbcs': dot substituted for
## Warning in text.default(x, y, ...): conversion failure on 'meżczyzna' in
## 'mbcsToSbcs': dot substituted for <c4>
## Warning in text.default(x, y, ...): conversion failure on 'meżczyzna' in
## 'mbcsToSbcs': dot substituted for <99>
## Warning in text.default(x, y, ...): conversion failure on 'meżczyzna' in
## 'mbcsToSbcs': dot substituted for <c5>
## Warning in text.default(x, y, ...): conversion failure on 'meżczyzna' in
## 'mbcsToSbcs': dot substituted for <br/>
## Warning in text.default(x, y, ...): conversion failure on 'meżczyzna' in
## 'mbcsToSbcs': dot substituted for <br/>
## Warning in text.default(x, y, ...): conversion failure on 'meżczyzna' in
```



marginesy

```
par(mar=c(3,12,3,3)) # marginesy w kolejności par(mar=c(bottom, left, top, right)) #czyli dół, lewy, góra, prawy
```


```
barplot(domeny_gender,
        las = 1,
       beside = TRUE,
       horiz = TRUE)
legend("topright",
       c("mężczyzna", "kobieta"),
      fill = c("lightgrey", "gray39"))
## Warning in (function (s, units = "user", cex = NULL, font = NULL, vfont =
## NULL, : conversion failure on 'meżczyzna' in 'mbcsToSbcs': dot substituted for
## <c4>
## Warning in (function (s, units = "user", cex = NULL, font = NULL, vfont =
## NULL, : conversion failure on 'meżczyzna' in 'mbcsToSbcs': dot substituted for
## <99>
## Warning in (function (s, units = "user", cex = NULL, font = NULL, vfont =
## NULL, : conversion failure on 'meżczyzna' in 'mbcsToSbcs': dot substituted for
## <c5>
## Warning in (function (s, units = "user", cex = NULL, font = NULL, vfont =
## NULL, : conversion failure on 'meżczyzna' in 'mbcsToSbcs': dot substituted for
## <bc>
## Warning in text.default(x, y, \dots): conversion failure on 'mężczyzna' in
## 'mbcsToSbcs': dot substituted for <c4>
## Warning in text.default(x, y, ...): conversion failure on 'mężczyzna' in
## 'mbcsToSbcs': dot substituted for <99>
## Warning in text.default(x, y, ...): conversion failure on 'meżczyzna' in
## 'mbcsToSbcs': dot substituted for <c5>
## Warning in text.default(x, y, ...): conversion failure on 'mężczyzna' in
## 'mbcsToSbcs': dot substituted for <bc>
```



```
par(mar=c(5,12,3,3)) # marginesy w kolejności par(mar = c(bottom, left, top, right))
#czyli dół, lewy, góra, prawy
barplot(domeny_gender,
       las = 1,
       beside = TRUE,
       horiz = TRUE,
       xlab = "liczba biografii",
       main = "Biografie w zbiorze Panteon 1.0 według dziedziny działalności i płci")
## Warning in title(main = main, sub = sub, xlab = xlab, ylab = ylab, ...):
## conversion failure on 'Biografie w zbiorze Panteon 1.0 według dziedziny
## działalności i płci' in 'mbcsToSbcs': dot substituted for <c5>
## Warning in title(main = main, sub = sub, xlab = xlab, ylab = ylab, ...):
## conversion failure on 'Biografie w zbiorze Panteon 1.0 według dziedziny
## działalności i płci' in 'mbcsToSbcs': dot substituted for <82>
## Warning in title(main = main, sub = sub, xlab = xlab, ylab = ylab, ...):
## conversion failure on 'Biografie w zbiorze Panteon 1.0 według dziedziny
## działalności i płci' in 'mbcsToSbcs': dot substituted for <c5>
## Warning in title(main = main, sub = sub, xlab = xlab, ylab = ylab, ...):
## conversion failure on 'Biografie w zbiorze Panteon 1.0 według dziedziny
## działalności i płci' in 'mbcsToSbcs': dot substituted for <82>
```

```
## Warning in title(main = main, sub = sub, xlab = xlab, ylab = ylab, ...):
## conversion failure on 'Biografie w zbiorze Panteon 1.0 według dziedziny
## działalności i płci' in 'mbcsToSbcs': dot substituted for <c5>
## Warning in title(main = main, sub = sub, xlab = xlab, ylab = ylab, ...):
## conversion failure on 'Biografie w zbiorze Panteon 1.0 według dziedziny
## działalności i płci' in 'mbcsToSbcs': dot substituted for <9b>
## Warning in title(main = main, sub = sub, xlab = xlab, ylab = ylab, ...):
## conversion failure on 'Biografie w zbiorze Panteon 1.0 według dziedziny
## działalności i płci' in 'mbcsToSbcs': dot substituted for <c5>
## Warning in title(main = main, sub = sub, xlab = xlab, ylab = ylab, ...):
## conversion failure on 'Biografie w zbiorze Panteon 1.0 według dziedziny
## działalności i płci' in 'mbcsToSbcs': dot substituted for <82>
legend("topright",
       c("mężczyzna", "kobieta"),
       fill = c("lightgrey", "gray39"))
## Warning in (function (s, units = "user", cex = NULL, font = NULL, vfont =
## NULL, : conversion failure on 'meżczyzna' in 'mbcsToSbcs': dot substituted for
## <c4>
## Warning in (function (s, units = "user", cex = NULL, font = NULL, vfont =
## NULL, : conversion failure on 'meżczyzna' in 'mbcsToSbcs': dot substituted for
## <99>
## Warning in (function (s, units = "user", cex = NULL, font = NULL, vfont =
## NULL, : conversion failure on 'meżczyzna' in 'mbcsToSbcs': dot substituted for
## <c5>
## Warning in (function (s, units = "user", cex = NULL, font = NULL, vfont =
## NULL, : conversion failure on 'meżczyzna' in 'mbcsToSbcs': dot substituted for
## <bc>
## Warning in text.default(x, y, ...): conversion failure on 'meżczyzna' in
## 'mbcsToSbcs': dot substituted for <c4>
## Warning in text.default(x, y, ...): conversion failure on 'mężczyzna' in
## 'mbcsToSbcs': dot substituted for <99>
## Warning in text.default(x, y, ...): conversion failure on 'meżczyzna' in
## 'mbcsToSbcs': dot substituted for <c5>
## Warning in text.default(x, y, ...): conversion failure on 'mężczyzna' in
## 'mbcsToSbcs': dot substituted for <bc>
```


Biografie w zbiorze Panteon 1.0 wed..ug dziedziny dzia..alno



```
par(mar=c(5,12,3,3)) # marginesy w kolejności par(mar = c(bottom, left, top, right))
#czyli dół, lewy, góra, prawy
barplot(domeny_gender,
        las = 1,
        beside = TRUE,
       horiz = TRUE,
       xlab = "liczba biografii",
       main = "Biografie w zbiorze Panteon 1.0 \nwedług dziedziny działalności i płci")
## Warning in title(main = main, sub = sub, xlab = xlab, ylab = ylab, ...):
## conversion failure on 'według dziedziny działalności i płci' in 'mbcsToSbcs':
## dot substituted for <c5>
## Warning in title(main = main, sub = sub, xlab = xlab, ylab = ylab, ...):
## conversion failure on 'według dziedziny działalności i płci' in 'mbcsToSbcs':
## dot substituted for <82>
## Warning in title(main = main, sub = sub, xlab = xlab, ylab = ylab, ...):
## conversion failure on 'według dziedziny działalności i płci' in 'mbcsToSbcs':
## dot substituted for <c5>
## Warning in title(main = main, sub = sub, xlab = xlab, ylab = ylab, ...):
## conversion failure on 'według dziedziny działalności i płci' in 'mbcsToSbcs':
## dot substituted for <82>
```

```
## Warning in title(main = main, sub = sub, xlab = xlab, ylab = ylab, ...):
## conversion failure on 'według dziedziny działalności i płci' in 'mbcsToSbcs':
## dot substituted for <c5>
## Warning in title(main = main, sub = sub, xlab = xlab, ylab = ylab, ...):
## conversion failure on 'według dziedziny działalności i płci' in 'mbcsToSbcs':
## dot substituted for <9b>
## Warning in title(main = main, sub = sub, xlab = xlab, ylab = ylab, ...):
## conversion failure on 'według dziedziny działalności i płci' in 'mbcsToSbcs':
## dot substituted for <c5>
## Warning in title(main = main, sub = sub, xlab = xlab, ylab = ylab, ...):
## conversion failure on 'według dziedziny działalności i płci' in 'mbcsToSbcs':
## dot substituted for <82>
legend("topright",
       c("mężczyzna", "kobieta"),
       fill = c("lightgrey", "gray39"))
## Warning in (function (s, units = "user", cex = NULL, font = NULL, vfont =
## NULL, : conversion failure on 'meżczyzna' in 'mbcsToSbcs': dot substituted for
## <c4>
## Warning in (function (s, units = "user", cex = NULL, font = NULL, vfont =
## NULL, : conversion failure on 'meżczyzna' in 'mbcsToSbcs': dot substituted for
## <99>
## Warning in (function (s, units = "user", cex = NULL, font = NULL, vfont =
## NULL, : conversion failure on 'meżczyzna' in 'mbcsToSbcs': dot substituted for
## <c5>
## Warning in (function (s, units = "user", cex = NULL, font = NULL, vfont =
## NULL, : conversion failure on 'meżczyzna' in 'mbcsToSbcs': dot substituted for
## <bc>
## Warning in text.default(x, y, ...): conversion failure on 'meżczyzna' in
## 'mbcsToSbcs': dot substituted for <c4>
## Warning in text.default(x, y, ...): conversion failure on 'mężczyzna' in
## 'mbcsToSbcs': dot substituted for <99>
## Warning in text.default(x, y, ...): conversion failure on 'mężczyzna' in
## 'mbcsToSbcs': dot substituted for <c5>
## Warning in text.default(x, y, ...): conversion failure on 'mężczyzna' in
## 'mbcsToSbcs': dot substituted for <bc>
```

Biografie w zbiorze Panteon 1.0 wed..ug dziedziny dzia..alno..ci i p..ci




```
par(mar=c(5,12,3,3))
# Sortowanie według sum w kolumnach
sorted_indices <- order(colSums(domeny_gender), decreasing = TRUE)</pre>
# Zastosowanie sortowania do kolumn
domeny_gender_sorted <- domeny_gender[, sorted_indices]</pre>
# Tworzenie wykresu z posortowanymi danymi
barplot(
 domeny_gender_sorted,
 las = 1,
 beside = TRUE,
 horiz = TRUE,
  col = c("lightgrey", "gray39")
# Dodanie legendy
legend(
  "topright",
 c("kobieta", "mężczyzna"),
  fill = c("lightgrey", "gray39")
```

Warning in (function (s, units = "user", cex = NULL, font = NULL, vfont =
NULL, : conversion failure on 'meżczyzna' in 'mbcsToSbcs': dot substituted for

```
## Warning in (function (s, units = "user", cex = NULL, font = NULL, vfont =
## NULL, : conversion failure on 'meżczyzna' in 'mbcsToSbcs': dot substituted for
## <99>
## Warning in (function (s, units = "user", cex = NULL, font = NULL, vfont =
## NULL, : conversion failure on 'meżczyzna' in 'mbcsToSbcs': dot substituted for
## <c5>
## Warning in (function (s, units = "user", cex = NULL, font = NULL, vfont =
## NULL, : conversion failure on 'meżczyzna' in 'mbcsToSbcs': dot substituted for
## <bc>
## Warning in text.default(x, y, ...): conversion failure on 'mężczyzna' in
## 'mbcsToSbcs': dot substituted for <c4>
## Warning in text.default(x, y, ...): conversion failure on 'mężczyzna' in
## 'mbcsToSbcs': dot substituted for <99>
## Warning in text.default(x, y, ...): conversion failure on 'mężczyzna' in
## 'mbcsToSbcs': dot substituted for <c5>
## Warning in text.default(x, y, ...): conversion failure on 'mężczyzna' in
## 'mbcsToSbcs': dot substituted for <bc>
```

<c4>



Zadanie barplot według płci i kontynentów

```
dev.off()


## null device
## 1

?dev.off()


Wykres mozaikowy
?mosaicplot

mosaicplot(~domain+gender, data = panteon)
```

panteon








kolejność


(domeny_ko <- as.data.frame(table(panteon\$domain)))</pre>

```
##
                     Var1 Freq
## 1
                     ARTS 2866
## 2
           BUSINESS & LAW 108
## 3
              EXPLORATION 102
               HUMANITIES 1329
## 4
## 5
             INSTITUTIONS 3456
            PUBLIC FIGURE 358
## 6
## 7 SCIENCE & TECHNOLOGY 1366
## 8
                   SPORTS 1756
```

Zmienne typu factor i ustalanie ich porządku funkcją faktor

```
panteon$domain <- factor(panteon$domain, levels = domeny_ko$Var1)</pre>
```






wykres gęstości

plot(density(panteon\$HPI))

density.default(x = panteon\$HPI)



```
mężczyźni <- filter(panteon, gender == "Male")
kobiety <- filter(panteon, gender == "Female")</pre>
```

plot(density(mężczyźni\$HPI))

```
## Warning in title(...): conversion failure on 'density.default(x =
## meżczyźni$HPI)' in 'mbcsToSbcs': dot substituted for <c4>

## Warning in title(...): conversion failure on 'density.default(x =
## meżczyźni$HPI)' in 'mbcsToSbcs': dot substituted for <99>

## Warning in title(...): conversion failure on 'density.default(x =
## meżczyźni$HPI)' in 'mbcsToSbcs': dot substituted for <c5>


## Warning in title(...): conversion failure on 'density.default(x =
## meżczyźni$HPI)' in 'mbcsToSbcs': dot substituted for <bc>

## Warning in title(...): conversion failure on 'density.default(x =
## meżczyźni$HPI)' in 'mbcsToSbcs': dot substituted for <c5>

## Warning in title(...): conversion failure on 'density.default(x =
## meżczyźni$HPI)' in 'mbcsToSbcs': dot substituted for <ba>
```

```
par(new = TRUE)
plot(density(kobiety$HPI),
    col = "red")
```

detesitytylefelalt(tx(x =nkabie)ty\$1\$PIPI)




Usuniemy nakładające się elementy

?par()

plot(density(mężczyźni\$HPI))

```
## Warning in title(...): conversion failure on 'density.default(x =
## meżczyźni$HPI)' in 'mbcsToSbcs': dot substituted for <c4>
## Warning in title(...): conversion failure on 'density.default(x =
## meżczyźni$HPI)' in 'mbcsToSbcs': dot substituted for <99>
## Warning in title(...): conversion failure on 'density.default(x =
## meżczyźni$HPI)' in 'mbcsToSbcs': dot substituted for <c5>
## Warning in title(...): conversion failure on 'density.default(x =
## meżczyźni$HPI)' in 'mbcsToSbcs': dot substituted for <bc>
## Warning in title(...): conversion failure on 'density.default(x =
## meżczyźni$HPI)' in 'mbcsToSbcs': dot substituted for <c5>
```

density.default(x = m....czy..ni\$HPI)




ecdf - dystrybuanta empiryczna

Jaki procent obserwacji przyjmuje wartość mniejszą niż $\mathbf x$


```
plot(ecdf(panteon$AverageViews))
```

ecdf(panteon\$AverageViews)



plot(ecdf(panteon\$HPI))

ecdf(panteon\$HPI)



Pomoc

?help()

help(ggplot)

Katalog roboczy

Zasadniczo lepiej operować używając rproj w RStudio niż katalogu roboczego. Informacja o katalogu roboczym:

getwd()

[1] "/Users/golemxiv/Documents/dydaktyka/wizualizacjaR/podstawy"

Ustawianie katalogu roboczego

setwd() # argumentem jest ścieżka dostępu do katalogu roboczego w cudzysłowie

Error in setwd(): argument "dir" is missing, with no default

Skrypty

Skróty przydatne w skryptach:

ctrl enter - uruchamia zaznaczony fragment kodu ctrl shift enter - uruchamia cały skrypt

Praca domowa:

- tworzymy nowy projekt
- umieszczamy w nim plik z danymi
- tworzymy w nim plik r markdown który wczytuje potrzebne biblioteki, wczytuje dane i rysuje na ich podstawie wykres
- kompresujemy folder projektu
- wysyłamy na t.olczyk@uw.edu.pl
- notujemy wszelkie problemy, pytania i trudności jakie pojawią się w tym procesie

Co po zajęciach

Plan minimum:

Ściągawka Rstudio

Plan dla ambitnych

Rozdział 1-3 Long, J. D. (2020). Język R: Receptury: analiza danych, statystyka i przetwarzanie grafiki, (K. Sawka, Tłum.). Helion SA.

online po angielsku

Co przed następnymi zajęciami?:

Plan minimum:

Ściagawka ggplot

Plan dla ambitnych:

rozdział 1 z Wickham, H., & Grolemund, G. (2020). Język R: Kompletny zestaw narzędzi dla analityków danych (J. Zatorska, Tłum.). Wydawnictwo Helion.

online po angielsku